

Classification analysis&evaluation

4.1 Objective

본 모델은 전처리가 완료된 UNSW-NB15 데이터셋을 사용하였다.

입력 데이터는 X_train.csv, X_test.csv, 정답 라벨은 y_train.csv, y_test.csv로 분리되어

저장되어 있으며, 모델은 이를 불러와 학습과 평가를 수행한다.

모델의 목적은 UNSW-NB15 데이터셋을 이용하여 정상 네트워크 트래픽과 악성 네트워크 트래픽을 구분하는 것이다.

Random Forest 분류기를 사용하여 전처리된 네트워크 특징(feature)을 기반으로 각 네트워크 연결이 Normal 클래스(0)인지 Attack 클래스(1)인지 예측하도록 학습하였다.

Dataset	Samples	Features
Train set	80,688	182
Test set	61,336	182

Dataset	Normal	Attack
Train set	60,516	20,172
Test set	56,293	5,043

4.2 Model Setup

다음과 같은 Random Forest 설정을 사용하여 모델을 구성하였다.

RandomForestClassifier

(n_estimators=100, class_weight='balanced', max_depth=None,
random_state=42, n_jobs=-1)

```
[Step 2] Random Forest 모델 생성
n_estimators: 100
max_depth: None
random_state: 42
n_jobs: -1
```

4.3 Model Evaluation Method

```
[Step 2-1] 5-Fold CV 평가
Fold별 F1:
[0.96888347 0.96550043 0.96723907 0.96943018 0.97072457]

평균 CV F1:0.9684
표준편차:0.0018
```

모델 일반화 성능 평가를 위해 Stratified 5-Fold Cross Validation을 적용하였다.

각 Fold에서 클래스 비율이 유지되도록 설정하여 불균형 데이터 문제를 반영하였다.

평균 F1-score는 **0.9684**, 표준편차는 **0.0018**로 측정되었으며, 이는 서로 다른 검증 Fold에서도 안정적인 성능을 보였음을 의미한다.

평가 지표로는 다음 항목들을 사용하였다.

- Accuracy
- Precision
- Recall
- F1-score
- ROC-AUC

4.4 Hyperparameter Optimization (GridSearchCV)

최적의 Random Forest 모델 구성을 찾기 위해 GridSearchCV를 수행하였다.

다음 하이퍼파라미터 조합을 탐색하였다.

- n_estimators
- max_depth
- min_samples_split
- min_samples_leaf

```
최적 파라미터 :  
{'max_depth': 20, 'min_samples_leaf': 1, 'min_samples_split': 5, 'n_estimators': 100}  
최고 F1: 0.9682485463356243
```

[Step 4] Test 데이터 예측
예측 완료: 61,336개

[Step 5] 모델 성능 평가
Accuracy : 0.9820
Precision: 0.8267
Recall : 0.9877
F1-score : 0.9001

GridSearchCV를 통해 최적 하이퍼파라미터 조합을 찾았으며, 교차검증에서는 0.9682로 높은 평균 F1-score를 기록하였다.

그러나 독립적인 Test Dataset에서 평가했을 때는 기본 Random Forest 모델 0.9053보다 낮은 0.9001의 F1-score를 보였다.

따라서 보지 않은 데이터(Unseen Data)에 대한 일반화 성능이 더 우수한 기본 Random Forest 모델을 최종 모델로 선택하였다.


4.5 Threshold Optimization using Cross Validation

최적의 분류 Threshold를 찾기 위해 0.50 ~ 0.95 범위의 여러 Threshold 값에 대해 Stratified 5-Fold Cross Validation을 수행하였다.

각 Threshold마다 평균 F1-score를 계산한 결과, 낮은 Threshold에서는 높은 Recall로 인해 더 높은 F1-score가 나타났고, 높은 Threshold에서는 Recall 감소로 인해 전체 성능이 저하되는 경향을 보였다.

분석 결과 기본값인 Threshold = 0.5 부근에서 가장 높은 평균 F1-score가 나타났으며, Precision과 Recall 간의 균형도 가장 적절하였다.



따라서 최종 모델 평가에서는 Threshold = 0.5를 사용하였다.



```
[Step 2-2] Threshold Validation  
Threshold=0.50 | Mean F1=0.9682 | Std=0.0017  
Threshold=0.55 | Mean F1=0.9678 | Std=0.0015  
Threshold=0.60 | Mean F1=0.9667 | Std=0.0013  
Threshold=0.65 | Mean F1=0.9647 | Std=0.0012  
Threshold=0.70 | Mean F1=0.9611 | Std=0.0013  
Threshold=0.75 | Mean F1=0.9569 | Std=0.0014  
Threshold=0.80 | Mean F1=0.9493 | Std=0.0019  
Threshold=0.85 | Mean F1=0.9373 | Std=0.0017  
Threshold=0.90 | Mean F1=0.9180 | Std=0.0020  
Threshold=0.95 | Mean F1=0.8793 | Std=0.0043
```

4.6 Final Model Performance

최종 Random Forest 모델은 총 61,336개의 샘플을 포함한 독립적인 Test Dataset에서 평가되었다.



```
=====  
Random Forest 분류 완료  
5-Fold CV F1: 0.9684  
Threshold:0.5  
Accuracy : 0.9831  
Precision: 0.8402  
Recall : 0.9814  
F1-score : 0.9053  
=====
```

모델은 전체 Accuracy 98% 이상을 유지하면서 Attack 샘플의 98.14%를 성공적으로 탐지하였다.

다만 Precision(84.02%)은 상대적으로 낮게 나타났으며, 이는 일부 정상 트래픽이 공격으로 잘못 분류(False Positive)되었음을 의미한다.

이 현상은 학습 데이터와 테스트 데이터 간의 클래스 비율 차이에 영향을 받은 것으로 분석된다.

학습 과정에서는 원래 약 11:1이었던 클래스 비율(Normal)을 Downsampling을 통해 약 3:1로 조정하였다.

그 결과 모델이 공격 패턴에 더욱 민감하게 반응하게 되었고, 원래의 불균형 비율을 유지한 테스트 데이터셋에서는 일부 정상 트래픽을 공격으로 예측하는 False Positive가 증가하였다.

Results Summary

- 5-Fold CV F1-score: 0.9684
- Threshold: 0.5
- Accuracy: 0.9831
- Precision: 0.8402
- Recall: 0.9814
- F1-score: 0.9053

4.7 Confusion Matrix Analysis

Confusion Matrix를 통해 실제 레이블과 예측 결과를 비교 분석하였다.

모델은 전체 정상 트래픽 56,293개 중 55,352개를 정확히 분류하였으며(98.33%), 공격 트래픽 5,043개 중 4,949개를 성공적으로 탐지하였다(98.14%).


특히 False Negative는 단 94개만 발생하여 실제 공격 데이터를 정상으로 놓치는 경우가 매우 적었다.

이는 모델이 높은 Recall 성능과 강력한 공격 탐지 능력을 보였음을 의미한다.

반면 False Positive는 941개 발생하였으며, 일부 정상 트래픽이 공격으로 잘못 분류되었다.

하지만 이는 전체 정상 트래픽의 약 1.67% 수준으로 비교적 낮은 비율이다.


이러한 결과는 학습 시 적용한 Downsampling 전략이 공격 탐지 민감도를 향상시키는 대신 False Positive를 일부 증가시킨 영향으로 분석된다.



4.8 ROC Curve Analysis

ROC Curve 분석은 Random Forest 모델이 생성한 예측 확률값을 기반으로 수행되었다. ROC-AUC Score는 다양한 Threshold에서 모델의 전체 분류 성능을 평가하는 지표이다. 본 모델은 ROC-AUC Score 0.9983을 기록하였으며, 이는 정상 트래픽과 공격 트래픽을 매우 우수하게 구분하고 있음을 의미한다.

ROC Curve 또한 좌측 상단에 가까운 형태를 보였으며, 이는 False Positive Rate를 낮게 유지하면서 높은 True Positive Rate를 유지했음을 나타낸다.



4.9 Feature Importance Analysis

Random Forest 모델에서 추출한 Feature Importance 값을 이용하여 공격 탐지에 가장 큰 영향을 준 변수를 분석하였다.

그 결과 **sttl**, **ct_state_ttl**, **dttl** 특징이 가장 높은 중요도를 보였다.

이는 TTL(Time To Live) 관련 네트워크 특징이 정상 트래픽과 악성 트래픽을 구분하는 데 중요한 역할을 했음을 의미한다.

또한 네트워크 상태 정보와 패킷 단위 특징들이 높은 중요도를 보인 것은 모델이 공격과 관련된 의미 있는 트래픽 패턴을 효과적으로 학습했음을 나타낸다.

모델 해석 가능성을 높이기 위해 상위 20개 Feature를 Importance Score 기준으로 시각화하였다.

